

1.

$$h(x, y) = \frac{1}{4} (g(x+y, x+y) - g(x-y, x-y))$$

۱.

با استفاده از:

$$= \frac{1}{4} (g(x, x+y) + g(y, x+y) - g(x, x-y) - g(-y, x-y)) \quad (ب)$$

$$f(x, y+z) = f(y+z, x) = f(y, x) + f(z, x) = f(x, y) + f(x, z)$$

$$f(x, \alpha y) = f(\alpha y, x) = \alpha f(y, x) = \alpha f(x, y)$$

از آنجایی که تقارن داریم خطی ب دج برای هر دو آرگومان برقرار است.

$$h(x, y) = \frac{1}{4} (g(x, x) + g(x, y) + g(y, x) + g(y, y) - g(x, x) + g(x, y) + g(y, x) - g(y, y))$$

$$= \frac{1}{4} (2g(x, y) + \underbrace{2g(y, x)}_{=g(x, y)}) = g(x, y)$$

پس  $h(x, y) = g(x, y)$  و اگر  $g$  هستی محب است  $h$  هم محب است.

2. در فضای قسمت ها از آنجا که  $k_1$  و  $k_2$  هسته های صحیح هستند پس  $\phi_1$  و  $\phi_2(x)$  وجود دارد به طوری که :

$$k_1(x, y) = \phi_1^T(x) \phi_1(y)$$

$$, k_2(x, y) = \phi_2^T(x) \phi_2(y)$$

$$k_3(x, y) = k_1(x, y) + k_2(x, y) = \phi_1^T(x) \phi_1(y) + \phi_2^T(x) \phi_2(y) \quad \text{آ}$$

$\phi_3$  را چنین تعریف میکنیم :

$$\phi_3^T(x) = [\phi_1(x)_1, \phi_2(x)_1, \phi_1(x)_2, \phi_2(x)_2, \dots]$$

(ابتدا  $\phi_1$  سپس  $\phi_2$  را، نام چون از متناهی بودن  $\phi_1$  و  $\phi_2$  مطمئن نیستیم)

حالا به سادگی میتوانیم :

$$\begin{aligned} \phi_3^T(x) \phi_3(y) &= \sum \phi_1(x)_i \phi_1(y)_i + \sum \phi_2(x)_i \phi_2(y)_i \\ &= \phi_1^T(x) \phi_1(y) + \phi_2^T(x) \phi_2(y) = k_3(x, y) \end{aligned}$$

پس  $k_3$  را به نرم  $\phi_3^T(x) \phi_3(y)$  نوشتیم که در کنار مقایسه لازم کافی هستند.

$$k_3(y, x) = k_1(y, x) + k_2(y, x) = k_1(x, y) + k_2(x, y) = k_3(x, y)$$

پس آا یک هسته صحیح است.

$$k_4(x, y) = k_1(x, y) k_2(x, y)$$

ب

$$k_4(y, x) = k_1(y, x) k_2(y, x) = k_1(x, y) k_2(x, y) = k_4(x, y) \quad \text{تقارن :}$$

$$k_4(x, y) = \phi_1^T(x) \phi_1(y) \cdot \phi_2^T(x) \phi_2(y) \quad \text{بهر این نگاشت :}$$

$$= \sum_i \phi_1(x)_i \phi_1(y)_i \cdot \sum_j \phi_2(x)_j \phi_2(y)_j$$

$$= \sum_{i,j} \phi_1(x)_i \phi_2(x)_j \cdot \phi_1(y)_i \phi_2(y)_j$$


حال که فرض است یک ترتیب روی لغاتهای  $(i, j)$  بگیریم که سپس مع

راوی یک مشخصه بزنیم. درصورتی که  $\phi_1$  و  $\phi_2$  ابعاد محدود داشته باشند

که کار راحت است. ابتدا روی یک  $\phi$  مدونیم و سپس روی دیگری. اما در حالیکه

مجموعه وجود دارد که در ابعادی نهایی هم کار کند،  $n$  را ترتیب دهیم به دیتای ما

دو این مجموعه تعریف کنیم :



$$(i, j) \rightarrow n$$

مثلاً

$$(0, 0) \rightarrow 0$$

$$(0, 1) \rightarrow 1$$

$$(1, 0) \rightarrow 2$$

$$(2, 0) \rightarrow 3$$

⋮

حال تعریف میکنیم :

$$\phi_4(x)_n \equiv \phi_1(x)_{i(n)} \phi_2(x)_{j(n)}$$

و جمع میشود :

$$K_4(x, y) = \sum_n \phi_4(x)_n \phi_4(y)_n$$

$$= \phi_4^T(x) \phi_4(y)$$

و هسته صحیح است .

نکته : اگر ابعاد یکی از  $\phi$  ها (بدون است از یک  $\phi_2$ ) محدود است میتوانیم از ضرب کردن استفاده کنیم (ترتیب  $n$  طوری است که ابتدا اولین مولفه  $\phi_1$  در  $\phi_2$  ضرب میشود و سپس بقیه  $\phi_1$  در  $\phi_2$  و ... و با اتحادهای حروف گرفته حاصل بدیهی است :

$$\phi_4(x) \equiv \phi_1(x) \otimes \phi_2(x)$$

$$\phi_4^T(x) \phi_4(y) = [\phi_1(x) \otimes \phi_2(x)]^T [\phi_1(y) \otimes \phi_2(y)]$$

$$= [\phi_1^T(x) \otimes \phi_2^T(x)] [\phi_1(y) \otimes \phi_2(y)] = K_4(x, y)$$

$$= \underbrace{[\phi_1^T(x) \phi_1(y)]}_{|x| \text{ عدد}} \otimes \underbrace{[\phi_2^T(x) \phi_2(y)]}_{|x| \text{ عدد}} = \phi_1^T(x) \phi_1(y) \phi_2^T(x) \phi_2(y)$$

$$k_5(x, y) = e^{k_1(x, y)}$$

ج ۲

$$k_5(y, x) = e^{k_1(y, x)} = e^{k_1(x, y)} = k_5(x, y) \quad \text{تقارن برقرار است}$$

قضیه: اگر  $\alpha > 0$  باشد و  $K$  همبسته محبته باشد  $\alpha K$  همبسته محبته است.

$$\alpha k(x, y) = \alpha \phi(x)^T \phi(y) = (\sqrt{\alpha} \phi(x))^T (\sqrt{\alpha} \phi(y)) \quad \text{اثبات}$$

$$\alpha k(y, x) = \alpha k(x, y) \quad \text{تقارن هم برقرار است}$$

حال:

$$\begin{aligned} k_5(x, y) = e^{k_1(x, y)} &= 1 + k_1(x, y) + \frac{k_1(x, y)^2}{2!} + \frac{k_1(x, y)^3}{3!} + \dots \\ &= \sum_{n=0}^{\infty} \frac{k_1(x, y)^n}{n!} \end{aligned}$$

ادعا میکنم هر جملی مجموع یک کرنل محبته است:

$$\frac{k_1(x, y)^n}{n!} = \underbrace{\left[ \underbrace{k_1(x, y) \cdot k_1(x, y)}_{\text{محبته}} \cdot \dots \cdot k_1(x, y) \right]}_{\text{محبته طبق ب}} \times \frac{1}{n!}$$

محبته طبق ب

محبته طبق قضیه ابتدای فصل  $(\frac{1}{n!} > 0)$

۱- هم هستی محبر است چرا که هم متقارن است هم مثبت معین.

حال که هر کدام از جلات جمع هستی محبر هسته لاجرم هم هستی محبر است

چون طبق (آ) جمع هر دو هستی محبر یک هستی محبر است.

$$K_6(x, y) = (1 - x^T y)^{-1} \quad (D)$$

تقارن برده‌ای است:

$$K_6(y, x) = (1 - y^T x)^{-1} = (1 - \underbrace{(x^T y)^T}_{= x^T y})^{-1} = K_6(x, y)$$

هسته محبر نیست. مثال نقض می‌آوریم. فرض کنید بعد فضا ۱ است و

$$K_6(x, y) = \frac{1}{1 - x^T y} = \frac{1}{1 - x_0 y_0}$$

$$A_{1 \times 1} = \left[ \frac{1}{1 - x_0^2} \right] \quad \text{ماتریس گرام هسته روی تک داده تک جوی و مشد:$$

$$A = \left[ \frac{-1}{3} \right] \quad \text{حالت ارضی بهم} \quad x_0 = 2$$

$$z^T A z = [z_0] \left[ \frac{-1}{3} \right] [z_0] = \frac{-1}{3} z_0^2 \quad \text{که برای } z_0 = 1 \text{ کوچکتر از صفر است.}$$

3. ورودی  $\hat{K}$  بر مجموعه است. که فرضی مورد علامتی ما این دو دوزیر مجموعی  
 دلخواه از  $X$  هستند.

$$\hat{K}(B, A) = \sum_{\substack{x \in B \\ x' \in A}} k(x, x') \quad \text{تعارف:}$$

با توجه به متغیر بودن  $k$  و dummy بودن  $x$  و  $x'$  اسم آن ها را عوض کنیم. (و در  $k$  هم جابه‌جا کنیم)

$$\hat{K}(B, A) = \sum_{\substack{x' \in B \\ x \in A}} k(x, x') = \hat{K}(A, B)$$

$k$  محاسبه است پس  $\phi$  و به عبارتی دیگر:

$$\hat{K}(A, B) = \sum_{\substack{x \in A \\ x' \in B}} \phi(x)^T \phi(x') = \sum_{x \in A} \sum_{x' \in B} \phi(x)^T \phi(x')$$

$$= \left[ \sum_{x \in A} \phi(x)^T \right] \left[ \sum_{x' \in B} \phi(x') \right] = \left[ \sum_{x \in A} \phi(x) \right]^T \left[ \sum_{x' \in B} \phi(x') \right]$$

پس تبدیل مناسب فرضی  $\hat{X}$  را داریم:

$$\hat{\phi}(A) = \sum_{x \in A} \phi(x)$$

$$\hat{K}(A, B) = \hat{\phi}(A)^T \hat{\phi}(B) \quad \text{حال:}$$

این دیگر تعاریف محاسبه بودن هسته را می‌دهد.

2. ا. در درس بعدیم با نرمالایز کردن ضرایب حاصلش برابر میشه با:

$$\rho = \frac{1}{\|w\|} \Rightarrow \frac{1}{\rho^2} = \|w\|^2$$

$$\frac{1}{\rho^2} = \left\| \sum_i \alpha_i \gamma_i x_i \right\|^2 = \sum_{i,j} \alpha_i \alpha_j \gamma_i \gamma_j k(x_i, x_j)$$

جمع مقابله‌ای جلاتی که  $\alpha$  نامزد دارند هم است. SV ها هستند. می‌دانیم

برای SV ها این شرط برقرار است.

$$\gamma_i (w^T x_i + b) = 1 \quad \text{شرط } KKT$$

$$w^T x_i + b = \frac{1}{\gamma_i} = \sum_j \alpha_j \gamma_j k(x_i, x_j) + b \quad *$$

$$\frac{1}{\rho^2} = \sum_i \alpha_i \gamma_i \underbrace{\sum_j \alpha_j \gamma_j k(x_i, x_j)}_{*} \quad \text{حال برگردیم به } \frac{1}{\rho^2} :$$

$$= \frac{1}{\gamma_i} - b$$

$$= \sum_i \alpha_i \gamma_i \left( \frac{1}{\gamma_i} - b \right) = \sum_i \alpha_i - b \sum_i \alpha_i \gamma_i$$

$$\Rightarrow \rho = \frac{1}{\sqrt{\sum_i \alpha_i}}$$





2. به نظر من  $robust$  است چرا که فلسفی SVM انتخاب جواب‌دهی از بین جواب‌دهنده‌های ممکن است که  $margin$  کمینه در آن بیشینه می‌شود.

حالا فرض کنید به داده‌هایی که داریم یک ویژگی جدید اضافه کنیم که تاثیری در فاصله‌ی آن‌ها از ابرصفحه ( $margin$ ) ندارد پس  $support+vector$  همان‌ها می‌مانند و در نتیجه همان  $\alpha$  های قبلی پاسخ مسئله هستند.

با توجه به بحث قبلی می‌توانیم که  $\alpha$  های قبلی مطابق انتظار  $m$  را تغییر نمی‌دهند (متمم تابع  $\alpha$  ثابت).

البته در  $w$  ها یک تغییر جدید اضافه می‌شود که انتظار داریم نزدیک‌ترین به  $m$  حال در  $classification$  تاثیری نمی‌گذارد زیرا می‌دانیم  $margin$  داده‌ها عوض نشده.


(مگر در ویژگی جدید داده‌ها نسبت به جواب‌دهنده‌های این مسئله که نتیجه‌ی عملی می‌شود به یکی دیگر گون شود ولی  $margin$  با توجه به اینکه این مسئله عوض نشود که با توجه به این که جمع جوی بی ربط است جدیدی را هم منظور این باشد.)

3. فرض کنید دقیقاً دو داده‌ای آموزش داریم که  $+1$  و  $-1$  دارند (متفاوت)

$P_+$ ،  $P_-$  و صبراً محقق سه نقطه در فضای  $d$  بعدی هستند که یک ابرمستقیم (؟)

تشکیل می‌دهند. صفی این سه نقطه را بررسی می‌کنیم. (یا آنکه هر کدام از  $P_+$

و  $P_-$  روی مبرایند این دو و یک خطی دلخواه دیگر)



به طور مستقیمی واضح است margin همیشه اگر صاف نخواهد بین دو نقطه باشد

زمانی است که صاف برابر با نصفی عمود منصف باره خط واصل  $P_+$

و  $P_-$  باشد و مقدار margin برابر با نصف فاصله بین دو نقطه است.

وینست صفت  $x_+$  و  $x_-$  support vector

حکایت صاف را داریم هر چند آن معلوم است.

$$\sum \alpha_i \gamma_i = \alpha_+ - \alpha_- = 0 \quad \underline{\underline{\text{اما هر دو هم نشان میدهیم}}}$$

$$\Rightarrow \alpha_+ = \alpha_- \equiv \alpha$$

$$\Rightarrow w = \sum \alpha_i \gamma_i x_i = \alpha (x_+ - x_-)$$

بردار عمود صاف در جهت خط واصل دو نقطه است. مان چیزی را حدس زدیم!

$$w^T x_+ + b = 1 = \alpha x_+^2 - \alpha x_+^T x_- + b$$

$$w^T x_- + b = -1 = \alpha x_-^2 - \alpha x_+^T x_- + b$$

$$L = \alpha_1 + \alpha_2 - \frac{1}{2} \left[ \alpha_1^2 X_+^2 + \alpha_2^2 X_-^2 - 2\alpha_1\alpha_2 X_+^T X_- \right]$$

$$= 2\alpha - \frac{1}{2} \alpha^2 \|X_+ - X_-\|^2$$

$$\frac{\partial L}{\partial \alpha} = 2 - \alpha \|X_+ - X_-\|^2 \Rightarrow \alpha = \frac{2}{\|X_+ - X_-\|^2} > 0 \quad \checkmark$$

جواب! از بخش اول می‌سیم

$$\rho = \frac{1}{\sqrt{\Sigma \alpha}} = \sqrt{\frac{\|X_+ - X_-\|^2}{4}} = \left\| \frac{X_+ - X_-}{2} \right\|$$

که بعد صفا بین دو نقطه است.

$$\Rightarrow w = 2 \frac{X_+ - X_-}{\|X_+ - X_-\|^2} \Rightarrow \|w\| = \frac{2}{\|X_+ - X_-\|}$$

$$X_+^T \frac{2}{\|X_+ - X_-\|^2} (X_+ - X_-) + b = 1 \quad [X_+ \text{ برای } KTT]$$

$$\Rightarrow b = \frac{X_+^2 + X_-^2 - 2X_+^T X_- - 2X_+^2 + 2X_+^T X_-}{\|X_+ - X_-\|^2}$$

$$d = \frac{|w^T x + b|}{\|w\|}$$

فاصله نقطه  $x$  از صفحه:

$$d(x=0) = \frac{|b|}{\|w\|} = \frac{\|X_+ - X_-\|}{2} \cdot \frac{|X_+^2 - X_-^2|}{\|X_+ - X_-\|^2}$$

$$d(x=0) = \left| \begin{bmatrix} \frac{x_+ - x_-}{\|x_+ - x_-\|} \\ 2 \end{bmatrix}^T \frac{x_+ + x_-}{2} \right|$$

پروجکشن کن جهت  $\hat{w}$   
 (که دانستیم همان جهت خط اول دو  
 نقطه است.)

نقطه‌ی وسط بین دو داده را  
 (که دانستیم صفحہ از آن عبور می‌کند)

$$L_{\epsilon}(x^{(i)}, y^{(i)}, f) = \max(0, |y^{(i)} - f(x^{(i)})| - \epsilon) \quad 3.1$$

$$y^{(i)} - f(x^{(i)}) - \epsilon \geq \xi_n^* \quad (y^{(i)} \geq f(x^{(i)}))$$

$$f(x^{(i)}) - y^{(i)} - \epsilon \geq \xi_n \quad (y^{(i)} < f(x^{(i)}))$$

$$\xi_n^*, \xi_n \geq 0 \quad \text{تعابین } \xi \quad \text{باشند:}$$

در صورتیکه از  $\xi_n$  یا  $\xi_n^*$  صفر است چون بالازره یا بیشینه بیشتر است یا کمتر و ممکن است فرد منوشونه (آزهای داخل بازوی  $\epsilon$  می باشد)

$$\max(0, |y^{(i)} - f(x^{(i)})| - \epsilon) = \xi_i^* + \xi_i \quad \text{پس:}$$

$$\min \frac{1}{2} \|W\|^2 + C \sum_{i=1}^N (\xi_i^* + \xi_i) \quad \text{نهایتاً:}$$

$$\text{subject to } \xi_i, \xi_i^* \geq 0$$

$$L = \frac{1}{2} W^T W + C \sum_i (\xi_i^* + \xi_i) \quad 2.$$

$$\left. \begin{aligned} - \sum \alpha_i^* (y_i - W^T x_i + \epsilon + \xi_i^*) \\ - \sum \alpha_i (W^T x_i - y_i + \epsilon + \xi_i) \\ - \sum \beta_i \xi_i - \sum \beta_i^* \xi_i^* \end{aligned} \right\} \begin{aligned} \text{شرط ها به فرم} \\ \geq 0 \end{aligned}$$

$$\nabla_W L = W - \sum \alpha_i x_i + \sum \alpha_i^* x_i = 0$$

$$W = \sum (\alpha_i - \alpha_i^*) x_i$$

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i = 0 \quad \beta_i \geq 0 \Rightarrow \alpha_i \leq C$$

$$\frac{\partial L}{\partial \xi_i^*} = C - \alpha_i^* - \beta_i^* = 0 \quad \beta_i^* \geq 0 \Rightarrow \alpha_i^* \leq C$$

بافز کربن یک علامت منفی مسئله به بیشینه تبدیل می‌شود. (میانجانه ای متفاوت به حساب می‌آید) (جمله ای در گرانترین منفی شده).

$$-\frac{1}{2} W^T W = -\frac{1}{2} \left[ \sum (\alpha_i - \alpha_i^*) x_i \right]^T \left[ \sum (\alpha_j - \alpha_j^*) x_j \right]$$

$$= -\frac{1}{2} \sum (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle$$

گرانترین به حساب می‌آید،  $\alpha_i^*$  و  $\alpha_j^*$  ها خطی است پس فریب آن‌ها را می‌توان نشان است و می‌توانست. فریب  $W^T$  هم همین‌طور.

$$\max -\frac{1}{2} \sum (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle$$

$$= \frac{1}{2} \sum (\alpha_i + \alpha_i^*) + \sum \gamma_i (\alpha_i - \alpha_i^*)$$

درسته!  $\alpha_i, \alpha_i^* \leq C$  را داریم و شرط  $\alpha_i, \alpha_i^* \geq 0$  هم از قبل داریم.

$$\alpha_i, \alpha_i^* \in [0, C]$$

3. به درستی که  $\alpha_i$  و  $\alpha_i^*$  هارادیک دسته‌تربهم شد  $\lambda$  (د 2N تاهسته)  
 مسند به حساب  $\lambda$  ما quadratic است چون هدی بکلت به شکل  $\lambda_i \lambda \sim$   
 $\lambda_i \sim$  هسته.

4. شرط KKT دبرای این لگالانترین داریم چنین هسته:

$$\alpha_i (\xi_i + \epsilon + y^{(i)} - f(x^{(i)})) = 0$$

$$\alpha_i^* (\xi_i^* + \epsilon + f(x^{(i)}) - y^{(i)}) = 0$$

support vector هان هدی هسته که یک از  $\alpha_i$  یا  $\alpha_i^*$  آن هان هدی باشد یعنی  
 عبارت مت راست  $\alpha_i$  یا  $\alpha_i^*$  برای آن ها باید هدی شد:

$$\xi_i + \epsilon + y^{(i)} - f(x^{(i)}) = 0$$

$$\xi_i^* + \epsilon + f(x^{(i)}) - y^{(i)} = 0$$

با اعال  $\xi_i, \xi_i^* \geq 0$

$$\xi_i = f(x^{(i)}) - y^{(i)} - \epsilon \geq 0$$

$$\xi_i^* = y^{(i)} - f(x^{(i)}) - \epsilon \geq 0$$

$$\Rightarrow |y^{(i)} - f(x^{(i)})| \geq \epsilon$$

support vector هان هدی هسته که رو یا فابج ازنی خطای  $\epsilon$  هسته.  
 (مقدار بیشین شده برای آن ها  $\epsilon$  یا بیشتره بیشتر یا  $-\epsilon$  یا کمتره است).

$$w = \sum_i (\alpha_i - \alpha_i^*) x_i \Rightarrow w^T x' = \sum_i (\alpha_i - \alpha_i^*) x_i^T x' \quad 5$$

به تنه‌فرب داخلی  $x_i$  های یادگیری ظاهر می‌شوند با تبدیل  $\phi(x) \rightarrow x$  این  
 حالت  $K(x_i, x')$  تبدیل می‌شود که بعد برای تلاش آنها دانستن کرنل فضای  
 مقصود کافی است. (رابطه یک کرنل دیگر می‌باشد)

6.  $\epsilon$  بازه‌ای است که در داخل آن داده‌ها داریم  $\epsilon$  penalize نمی‌شوند. در حد  $\epsilon \rightarrow 0$

همه‌ی داده‌ها داخل می‌شوند و در واقع جمع فواصل از بیشترین دالته ممکن (بسیار دالته‌ساز)  
 معادلی ولی خود فواصل نه توان نوشتن

$C$  در واقع محاسبه‌ی  $\frac{1}{2} \|w\|^2$  بهینه‌سازی با قلمی  $\|w\|^2$  است.

در حد  $C \rightarrow \infty$  تنها جواشتن داده‌ها مهم می‌شود و اثری که طرح داریم و

در  $C$  های کوچک  $\|w\|^2$  مهم می‌شود که با کمینه کردن  $\|w\|^2$ ،  $\frac{1}{\|w\|}$  را

بیشینه می‌کنیم که حاصل margin است. دالته اینجا آرگون margin د

به همان شکل قبل درجه‌ی تعریف کرد  $C$  کوچک همان  $\|w\|^2$  اندازه‌ی

بردار وزن‌ها را کم می‌کند که از لورفت جلوتر می‌رود.



4. 1. اگر support vector نباشد هیچ تخصیصی رخ نمی دهد. اما اگر باشد مرتبه

بست آن حرکت می کند و اگر آن نقطه مرزی دیده و اما آن سرز می تواند بزرگتر شود.

البته حالت های هم هست که در آن حذف حتی نقاط support vector (کلی) باعث

تغییر جواب است. SVM, margin ترسند. (مثلا در درجه سه نقطه از طرف دی

margin داریم.

به نظر من در logistic regression هوای مرتبیم با حذف شدن یکی از داده ها جابجا

میشود. به اگر در این رگرسیون های داده ها هوای دخیل هستند و چیزی به عنوان

support vector نداریم.

2. فرض کنید که یک نامرزشده یعنی margin را در کرده. این نزدیک به معنی

استیاه classify شدن نیست. چکن است بین دسته بندی تا مرز margin باشد

اما حد بالای فریب است:

$$N_{\text{wrong}} \ll \sum_i \theta(\xi_i)$$

$$\theta(x) = \begin{cases} 0 & x \leq 0 \\ 1 & x > 0 \end{cases}$$

هوای بهتری وجود دارد.  $\gamma_i (w^T x_i) < 0 \Rightarrow 1 - \xi_i < 0$

$\Rightarrow \xi_i > 1 \iff$  دسته بندی استیاه

$$N_{\text{wrong}} = \sum_i \Theta(\xi_i - 1) \leq \sum_i \xi_i$$

$$\downarrow$$

$$\xi_i \geq 0$$

3. اینجا دو عامل داریم که باهم مبارزه کنیم. یکی زیاد کردن margin تا جای ممکن و دیگری درست classifying کردن داده‌ها. می‌توان margin را خیلی زیاد کرد به‌های این که بسیاری از داده‌ها درست classifying نشوند یا margin باشد رافعی کم کرد و تعداد بیشتری از داده‌ها (hopefully) درست classifying شوند. هرکدام از این دو حاصل هم تأثیر منفی روی  $E_{\text{tot}}$  دارند. (اما داریم با وجود margin بزرگ  $E_{\text{tot}}$  کم شود و با کم شدن  $E_{\text{tot}}$  هم کم شود) پس جای بهینه‌ای برای فرامقدار  $C$  وجود دارد.

$C \rightarrow 0$  : خطا امنیت ندارد زیرا داشتن margin مهم است.  
 $C \rightarrow \infty$  :  $\underbrace{\text{margin}}_{\|w\|^2}$  هم نیست تا جای ممکن درست طبقه‌بندی کن.

4. اگر جوابی نه‌ی‌باشد SVM بین جواب‌های ممکن جواب را می‌دهد که بیشترین margin

را دارد اما LR لزوماً این کار را نمی‌کند بلکه ممکن خطای عددش را کم کند و کاری به

margin ندارد. (به‌نظم در عمده موارد SVM در این حالت بهتر است هر چند هزینه بیشتری دارد.

5.  $\text{soft SVM}$  نسبت به این که  $C$  به بیش انتخاب کنیم بین دو فاکتوری که بیشتر

گفتم (دسته بندی درست و  $\text{margin}$  زیاد) یک جواب می دهد ولی  $LR$

همچنان همان خطای خودش را کمینه میکند.

$LR$  احتمال (Likelihood) وقوع این تپا است را بیشینه میکند ولی  $\text{soft SVM}$

تاریکتری میکند.  $\text{soft SVM}$  در حدی که بدون نداشت استفاده بشود یک

جواب داده های خطی به ما میدهد که تپا قابل فهمه و ساده دی از  $LR$  است.