

(ب)

خب میدانیم که:

$$E = \frac{1}{N} \sum_{i=1}^N \exp(-y_i H_T(x_i))$$

و همچنین میدانیم که

$$H_T(x) = \sum_{t=1}^T \alpha_t h_t(x)$$

پس اگر این دو را در هم جاگذاری کنیم داریم:

$$E = \frac{1}{N} \sum_{i=1}^N \exp(-y_i \sum_{t=1}^T \alpha_t h_t(x_i)) = \sum_{i=1}^N \frac{1}{N} \exp(\sum_{t=1}^T -\alpha_t y_i h_t(x_i))$$

که همان حکم است.

(ت)

برای این ابتدا میبایم $D_{T+1}(i)$ رو نگاه میکنیم. داریم:

$$D_{t+1}(i) = \frac{D_t(i)}{Z_t} \exp(-\alpha_t y_i h_t(i))$$

$$\begin{aligned} \Rightarrow D_{T+1}(i) &= \frac{\exp(-\alpha_T y_i h_T(i))}{Z_T} D_T(i) = \frac{\exp(-\alpha_T y_i h_T(i))}{Z_T} \frac{\exp(-\alpha_{T-1} y_i h_{T-1}(i))}{Z_{T-1}} D_T(i) = \dots \\ &= \frac{\exp(-\alpha_T y_i h_T(i))}{Z_T} \frac{\exp(-\alpha_{T-1} y_i h_{T-1}(i))}{Z_{T-1}} \dots \frac{\exp(-\alpha_1 y_i h_1(i))}{Z_1} D_0(i) \\ &= \frac{1}{N} \frac{\exp(-\sum_{t=1}^T \alpha_t y_i h_t(i))}{\prod_{t=1}^T Z_t} = \frac{1}{N} \frac{\exp(-y_i H_T(x_i))}{\prod_{t=1}^T Z_t} \end{aligned}$$

خب حالا چون D_{T+1} توزیع است مجموعش ۱ میشود. پس:

$$\Rightarrow \sum_{i=1}^N D_{T+1}(i) = 1 \Rightarrow \sum_{i=1}^N \frac{1}{N} \frac{\exp(-y_i H_T(x_i))}{\prod_{t=1}^T Z_t} = 1 \Rightarrow E = \frac{1}{N} \sum_{i=1}^N \exp(-y_i H_T(x_i)) = \prod_{t=1}^T Z_t$$

(ث)

$$i=1$$

خب میدونیم که

$$Z_t = \sum_{i=1}^N D_t(i) \exp(-\alpha_t y_i h_t(x_i))$$

است. حالا اگر $y_i = h_t(x_i)$ باشد، $y_i h_t(x_i) = 1$ میشود و اگر $y_i \neq h_t(x_i)$ باشد، $y_i h_t(x_i) = -1$ میشود. پس عبارت بالا رو میتونیم به صورت زیر بنویسیم:

$$\begin{aligned} Z_t &= \sum_{y_i \neq h_t(x_i)} D_t(i) \exp(\alpha_t) + \sum_{y_i = h_t(x_i)} D_t(i) \exp(-\alpha_t) \\ &= \exp(\alpha_t) \sum_{y_i \neq h_t(x_i)} D_t(i) + \exp(-\alpha_t) \sum_{y_i = h_t(x_i)} D_t(i) \end{aligned}$$

خب اگر دقیق نگاه کنیم، میبینیم که $\epsilon_t = \sum_{y_i \neq h_t(x_i)} D_t(i)$ است. از طرفی چون D_t توزیع است داریم:

$$\sum_{y_i \neq h_t(x_i)} D_t(i) + \sum_{y_i = h_t(x_i)} D_t(i) = 1 \Rightarrow \sum_{y_i = h_t(x_i)} D_t(i) = 1 - \epsilon_t$$

پس:

$$\Rightarrow Z_t = \exp(\alpha_t) \epsilon_t + \exp(-\alpha_t) (1 - \epsilon_t)$$

(ج)

خب این هم ساده است. کافیه از Z_t بر حسب α_t مشتق بگیریم و مساوی صفر قرار بدیم.

$$Z_t = \exp(\alpha_t) \epsilon_t + \exp(-\alpha_t) (1 - \epsilon_t) \Rightarrow \frac{\partial Z_t}{\partial \alpha_t} = \exp(\alpha_t) \epsilon_t - \exp(-\alpha_t) (1 - \epsilon_t) = 0$$

$$\Rightarrow \exp(2\alpha_t) = \frac{1 - \epsilon_t}{\epsilon_t} \Rightarrow \alpha_t = \frac{1}{2} \ln\left(\frac{1 - \epsilon_t}{\epsilon_t}\right)$$

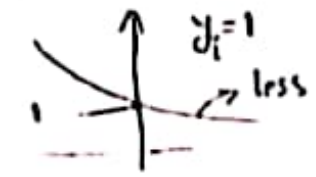
$$E = \frac{1}{N} \sum_{i=1}^N \exp(-y_i h_t(x_i)) = \frac{1}{N} \sum_{y_i = -1}^1 \exp(-y_i h_t(x_i)) \cdot \frac{1}{N} \sum_{y_i = -1}^1 \exp(-y_i h_t(x_i))$$

$$\gg \frac{1}{N} \sum_{y_i \neq \hat{y}_i} \exp(-y_i h_t(x_i)) \Rightarrow \text{loss} = \text{خطای کلاسیک است که}$$

نشان می‌دهد دسته‌بندی می‌شود چه چیزهای بیشتر از

$$\gg \frac{1}{N} \sum_{y_i \neq \hat{y}_i} 1 = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{y}_i \neq y_i)$$

دارد.



(ب)

ب) فرض کنید $D_t(i)$ توزیعی وزنی داده‌ها در مرحله t است. $D_{t+1}(i)$ را بر حسب x_i, y_i, α_t, D_t و دسته‌بند h_t بیابید. T گام نهایی است و به یاد داشته باشید Z_t عامل نرمال‌کننده D_{t+1} است:

$$Z_t = \sum_{i=1}^N D_t(i) \exp(-\alpha_t y_i h_t(x_i))$$

خب همان‌طور که ازین عامل نرمال‌کننده معلوم است، D_{t+1} برابر است با:


$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} = \frac{D_t(i) \exp(\alpha_t y_i h_t(x_i))}{\sum_{i=1}^N D_t(i) \exp(-\alpha_t y_i h_t(x_i))}$$

تمت

ادھانو

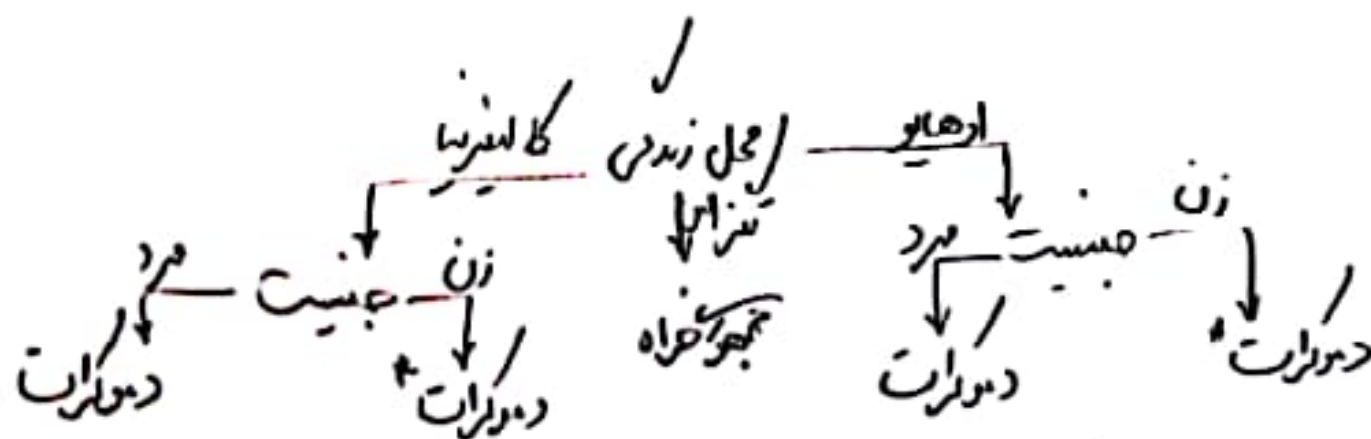
$G_1(\text{مرد})$: طایفه‌ای مرد

$$e_{11}(\text{---}) : \frac{1}{3} \left(\frac{1}{2} \left(\frac{1}{2} \right) + \frac{1}{2} \left(\frac{1}{2} \right) \right) = \frac{1}{3}$$



چہیت اسباب ملورد

کزو دلا هم در مستحق است بنابر این تا محقق در جهت مامی سرور



دوستان! می‌توان هم سکونت و هم جبری همراه دیگران رفت چنانچه امتثال برابری دارند.

$$\text{Gen. propensity for (تکرار)} = \frac{1}{2} \left[\frac{2}{5} \left(\frac{3}{5} \right) + \frac{3}{5} \left(\frac{2}{5} \right) \right] + \frac{1}{2} \left[\frac{3}{5} \left(\frac{2}{5} \right) + \frac{2}{5} \left(\frac{3}{5} \right) \right] = \frac{12}{25}$$

$$\text{GenI (محل زردی)} = \frac{4}{15} \left[\frac{1}{4} \left(\frac{3}{4} \right) + \frac{3}{4} \left(\frac{1}{4} \right) \right] + \frac{5}{15} [0] + \frac{3}{15} \left[\frac{1}{3} \left(\frac{2}{3} \right) + \frac{2}{3} \left(\frac{1}{3} \right) \right] = \frac{3}{24} + \frac{2}{15}$$

$$\text{GenI (همبست)} = \frac{1}{2} \left[\frac{2}{5} \left(\frac{3}{5} \right) + \frac{3}{5} \left(\frac{2}{5} \right) \right] + \frac{1}{2} \left[\frac{3}{5} \left(\frac{2}{5} \right) + \frac{2}{5} \left(\frac{3}{5} \right) \right] = \frac{12}{25} = 0.48$$

(محل زردی) GenII همیشه است پس میزان ریسک انتخاب می شود

مقایست مرئی در (1)
کاملاً تغییرنا

$$\text{GenI (تکرار)} = \frac{1}{4} [0] + \frac{3}{4} \left[\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right] = \frac{1}{3}$$

$$\text{GenI (همبست)} = \frac{1}{2} [0] + \frac{1}{2} \left[\frac{1}{2} \left(\frac{1}{2} \right) + \left(\frac{1}{2} \right) \left(\frac{1}{2} \right) \right] = \frac{1}{4}$$

همبست انتخاب می شود.

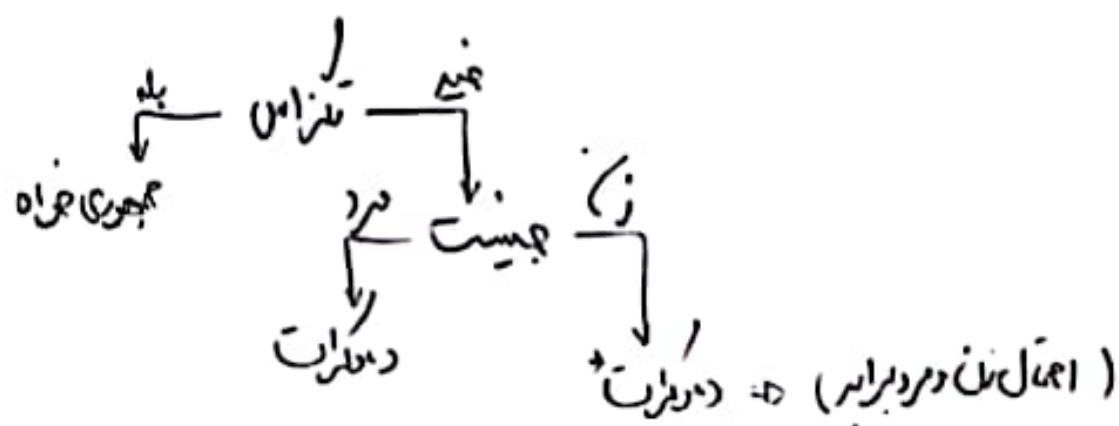
$$D_1, D_2, D_3 \xrightarrow{D_4} D_5 \text{ (کلیف)} = \frac{4}{7} \left[\frac{3}{4} \left(\frac{1}{4} \right) + \frac{1}{4} \left(\frac{3}{4} \right) \right] + \frac{3}{7} \left[\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right]$$

D_5, D_3, D_1 $\xleftarrow{D_4}$ D_2 $\xleftarrow{D_4}$ D_1

$$D_5, D_3, D_1 \xrightarrow{D_4} D_2 \text{ (اوهان)} = \frac{3}{7} \left[\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right] + \frac{4}{7} \left[\frac{3}{4} \left(\frac{1}{4} \right) + \frac{1}{4} \left(\frac{3}{4} \right) \right] = 0.45$$

D_1, D_2, D_3 $\xleftarrow{D_4}$ D_5

بکترین انتخاب کرده، جنسیت است. نامرئین رجعت به صورت زیر است



سه) زمانی که از multiple split استفاده می‌کنیم در نتیجه با binary split مقایسه می‌کنیم این دو روش
اما داده‌ها سریع می‌شکند و به زیر مجموعه‌های کوچک افزایش می‌دهد. بنابراین مدل ما بیشترین



overfit شدن پیدا می‌کند. یعنی به عنوان کردن داده‌ها در قسمت هم تقسیم می‌کنند و فارغ از مدل نسبت زیاد است.

در مقابل binary split مقایسه می‌کنیم اما دیرتر به دست overfit شدن می‌رسد و مدل‌های ساده‌تری

به دست می‌آید و فارغ از مقایسه می‌کنیم. در مقابل ممکن است این مدل به اندازه کافی دقیق نباشد و bias

بیشتری نسبت به Multi split داشته باشد.

۱۶۱
 برای تعیین داده‌ی نام از رویه‌ی استفاده می‌کنیم. داده‌ی دوزخ را با D و مجموعه‌ی خواص را با R نمایش می‌دهیم.
 بنابراین به‌طور مثال داده‌ی نام را با D_5 نمایش می‌دهیم.



$\text{argmax}_{i \in \text{remaining attr.}}$

$E_{\text{train}}(S, X_i) = \text{argmin}_{i \in \text{remaining attr.}} G_I(Y|X_i)$

۱. داریم که اگر در n باینری 2^n مقدار قدرت درخت تقسیم برابر با قدرت توابع $binary$ است. راه این کار جدول درستی
 بت تابع $binary$ با m مقصود در نظر بگیریم. این جدول 2^m مقدار دارد. چون دسته دو کلاس دارد هر مقدار را به جدول تبدیل می‌کنیم
 مقدار 2^m به 2^{2^m} تا درخت متفاوت داریم.

ب. می‌خواهیم جدول درخت را در جدول 2^m قرار دهیم. می‌توانیم که جدول را درخت تقسیم کنیم
 NP-complete است. یک مثال منفی برای جدول درخت. این مثال است که در درخت اول به نحوی $mutual info$
 ندارند اما در جدول 2^m از آن کشته. درخت درخت 2^m را می‌تواند درخت 2^m به نام
 است گفته می‌شود که درخت 2^m درخت 2^m است. بهترین درخت است؛ چرا که عمل است
 overfit کرده باشد.




0.0000	0.0000
0.0001	0.0001
0.0010	0.0010
0.0011	0.0011
0.0100	0.0100
0.0101	0.0101
0.0110	0.0110
0.0111	0.0111
0.1000	0.1000
0.1001	0.1001
0.1010	0.1010
0.1011	0.1011
0.1100	0.1100
0.1101	0.1101
0.1110	0.1110
0.1111	0.1111

به علاوه به این دلیل که در فرآیند ساختن درخت از حقیقت استفاده نمی‌کنیم، درخت بهینه کلی پیدا نخواهد شد.

ت) در این مورد جنگل تصادفی از معنی به اسم Bagging استفاده می‌شود. در Bagging ما با استفاده از تعدادی classifier قدرتمند، classifier ای می‌سازیم که وابستگی کمتری داشته باشد. به عبارت دیگر در Bagging وجود دارد این است که classifier های استفاده شده در آن باید با یکدیگر correlation نداشته باشند. به همین دلیل از تکنیک bootstrap aggregating استفاده می‌شود که در آن Dataset هایی باز عملی از Dataset مربع با جایگزینی برداشته می‌شود و هر classifier روی یک sample آموخته می‌شود. همچنین در جنگل تصادفی برای استقلال بیشتر هر بار یک زیرمجموعه از ویژگی‌ها را انتخاب می‌کنند و در نهایت روی آن آموخته می‌دهند. دلیل این امر آن است که اگر در بین ویژگی‌ها چند ویژگی خوب قدرتمند وجود داشته باشد در نهایت همراه آن‌ها را انتخاب می‌کنند و در نهایت همه را می‌کنند.

در این مورد بین پاسخ درخت‌های مختلف رأی گیری می‌شود به همین دلیل درخت‌های به خوبی درخت‌های با هم می‌مانند.

(د) برای این که سنده تبدیل به سنده binary شود می توانیم کد عمل زندگی را به صورت 32 موزان بیاوریم
(کالینز / ادیو / تنزاس) زندگی می کند / بلک




$$E_{11}(کالینز) = \frac{4}{10} \left(\frac{3}{4} \left(\frac{1}{4} \right) + \frac{1}{4} \left(\frac{3}{4} \right) \right) + \frac{6}{10} \left(\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right) = 0.417$$



$$E_{11}(تنزاس) = \frac{3}{10} [0] + \frac{7}{10} \left[\frac{5}{7} \left(\frac{2}{7} \right) + \frac{2}{7} \left(\frac{5}{7} \right) \right] = 0.286$$

$$E_{11}(ادیو) = \frac{3}{10} \left[\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right] + \frac{7}{10} \left[\frac{3}{7} \left(\frac{4}{7} \right) + \frac{4}{7} \left(\frac{3}{7} \right) \right] = 0.476$$


نزد اول / نزد تنزاس / نزد



$$E_{11}(نزد) = \frac{4}{7} \left(\frac{3}{4} \left(\frac{1}{4} \right) + \frac{1}{4} \left(\frac{3}{4} \right) \right) + \frac{3}{7} \left(\frac{2}{3} \left(\frac{1}{3} \right) + \frac{1}{3} \left(\frac{2}{3} \right) \right) = 0.45$$



$$E_{11}(جست) = \frac{3}{7} [0] + \frac{4}{7} \left[\frac{1}{2} \left(\frac{1}{2} \right) + \frac{1}{2} \left(\frac{1}{2} \right) \right] = 0.286$$



Problem 5.3

- (a) $M = 1$, we only have one hypothesis function.
- (b) Hoeffding bound $P[|E_{out} - E_{in}| > 0.02] \leq 2e^{-2 \times 0.02^2 \times N} = 0.0006709252558050237$. It says that for a high confidence, the out-of-sample error should be very close to our in-sample error, which is zero.
- (c) It's possible that the first N customers all come from same local area, i.e. we may have sample bias. So the model works on such sample but not on all samples.
- (d) The bank may apply your function to certain type of customers once it knows the implicit assumption in the function.