

1.

۱- اندازه‌ی جعبه‌ی فرقیه بسته به این داد دارد و نوع توابعی استفاده

کریم ولی مصدک لک با فرقیه لک بون توابع مورد استفاده نهایی

$2^N$  حالت ممکن است به این که تعداد حالات خوب باشد بون

معمولا هر کلام از امراد است.

$$P[|E_{in} - E_{out}| < \epsilon] \leq M e^{-2\epsilon^2 N} \quad - 2$$

$$P[|E_{in} - E_{out}| < 0.02] \leq 2 \times e^{-2 \cdot 0.02^2 \times 10000}$$

$$= e^{10000 \ln 2 - 2 \times 0.02^2 \times 10000}$$

$$= e^{10000 (\ln 2 - 2 \times 0.02^2)} > 1$$

پس جعبه‌ی فرقیه نهایی. تا وقت  $M$  را مورد دنگره ام جعبه‌ی فرقیه نهایی.

۱- تنها یک بار داده‌ها را sample گرفتن و فرقیه از یک سری فرمول‌های ریاضی

بدست آمده نه یادگیری پس مجموع فرقیه‌ها (تفاوت یک عضو دارد:  $M=1$ )

۲- با این تقاسم بانه‌ها فرقیه برای  $N=1000$  چنین می‌شود:

$$P[|E_{in} - E_{out}| < \epsilon] \leq 2 \times (1) \times e^{-\epsilon^2 N}$$

$$P \left[ \overbrace{|E_n - E_{out}|}^{= E_{out}} < 0.02 \right] \leq 2 e^{-0.02^2 \times 10000}$$

$$= 0.0366 = 3.66\%$$

ی‌کوبه احتمال این اتفاق (بخش 2) بیشتر مساری 96.34% است.

3- اولاً اگر برای 100 بانک این کار را انجام دهید برای مورد 4 تای آن‌ها

به طور متوسط خطا بیشتر از 2% خواهد بود البته گفته شد بیش از این

به تأخیر افتادن پس عینی فنی حاصل است و مشکل از جای دیگر است.

اولین دلیل ممکن به نظر من bias بودن داده‌ی ورودی است. ما تنها

آن‌هایی را به عنوان ورودی به تابع داریم و تست کردیم که توسط بانک بیشتر

تأخیر شده بودند پس الگوریتم (توابع ما) تأخیر حاصل می‌کند پس از دانستن کمیت

آن‌هایی را که توسط سیستم قبلی بانک رد می‌شوند نه به . اما حال به او

(پس از به کارگیری مدل توسط بانک) ورودی‌ای داده می‌شود که بیشتر توسط بانک

رد می‌شوند هیچ اثری از آن‌ها در ریت نیست و رد می‌شود. به نظر من

این‌ها هستند که تأثیر زیادی روی خطای نهایی گذاشته‌اند.

احتمال دیگر این است که مدل به دلیل پیچیدگی زیاد به داده‌ها overfit شده اما

به نظر من این خیلی نامحتمل است چه اگر تعداد دانه ها زیاد بود و اطلاعاتی  
 به اندازه و ما به عنوان نگاه کردن به دانه ها یک تابع ساختیم و آن را برای  
 دانه ها اعمال کنیم و  $E_{in} = 0$  که فیتیم. و اطلاعاتی هافدینگ قرار است همین  
 امکان لورنتز را به سبب کنی که  $(|E_{out} - E_{in}|)$  که می گویند نامحتمل است پس  
 مشکل همان بایاس بودن دانه ها بوده.

4 - به لعل این که ممکن روش لولیه (جمع ها) بکند را نگذاشت و از آن در گذر  
 این مدل استفاده که د. آن هایی که در روش لولیه تایید می شوند حال توسعه تابع ما از بایاس  
 می شوند و مدل ما با دقت خیلی بالایی در حل تعقیبات همان بانه هافدینگ با ما، عملاً  
 این را به سبب می کند و حل می توان آن هایی که در این رد می شوند رد کرد.  
 باین بار برای آن دره ای که در روش لولیه تایید می شوند خطای ما بهتر می شود و  
 اطمینان احتمالاً هم داریم. برای آن هایی که در روش لولیه رد می شوند هم خطاهای  
 خطای قبلی است.

آن هایی که درست لولیه رد می شوند را باید بتوان رد (تا تعداد رد شده ها کم  
 زیاد شود) یا بتوان دره ای از آن ها که تابع ما در مورد آن ها خیلی مطمئن  
 است را تایید کرد. (این جوابی حتی اگر دره ای آن ها  $f_{in}$  شوند در هر محوری

دهنده و اطمینان احتمالی داریم ریسک به درستی از آن ها که تایید میکنیم

البته این به شرطی بود که اعداد به استفاده از همان تابع داریم. اگر نمیتوانیم تابع را عوض کنیم نمیتوانیم تعدادی از رد شده ها را هم گزینش کنیم و محاسبه آن ها را بررسی کنیم. ممکن است بگویم  $E_{in} = 0$  نشود اما بهانه ها خدنگ درستی داریم.

ما میتوانیم تعداد زیادی از تایید شده ی لایه را جوی سمپل کرد که توزیع مشخصه های آن ها را سن، در آمو، ...،  $x$  ها، دسته توزیع صدی افراد (از جمله تایید لایه نشده ها) شود. این گونه bias را از بین میبریم.

۱-  $m$  ویژگی که کلام محدود به مقدار اختیار داشته  $2^m$  حالت ممکن **2.**

برای ویژگی‌ها به وجود می‌آورد. با استفاده از دقت می‌توان کلام از آن‌ها را از ویژگی  
کمینه داد و  $2^m$  برگ نه درخت داشت. کلام از  $2^m$  برگ دقت را می‌توان  
در یکی از دو دسته ی مسئله به دسته ترادار و کلام یک دقت جدید می‌دهد پس

$2^m$  دقت متفاوت داریم.


۲- خیر تنها در صورتی که همی اشکال مختلف دقت‌ها را در نظر بگیریم و برای  
کلام بهترین برگ‌ها را قرار دهیم و ببینیم کدام دقت بهتر بوده می‌توانیم  
بهترین دقت را بیابیم (که غیر ممکن است)

کارهای هزینه‌ای که local انجام شوند تنها ضارب بهینه ای local می‌رساند  
و ممکن است ما را از بهینه ی global دور کند. همچنین دقت‌های تقسیم  
مکن است به نوبه مردانه‌های پرت حساس باشد. ممکن است تقسیم هزینه‌ای  
ما که در لحظه Information Gain مثبتی دارد ناشی از یک داده‌ی پرت باشد که نهایتاً  
با دین داده‌ها تقسیم بی‌باشد.

۳- آ) ابتدا نگاه کنیم که چقدر دقت تقسیم کلام یک از ویژگی‌ها  
حسیت، زیاد یا حل زندگی را قرار دهیم / Gini Impurity کمتر دارد.

دستگاه = d


مجهز = r



$$gini(زن) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25}$$


$$gini(مرد) = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = \frac{12}{25}$$

$$gini = \frac{5}{10} \left(\frac{12}{25}\right) + \frac{5}{10} \left(\frac{12}{25}\right) = \frac{12}{25} = 0.48$$



$$gini = 0.48$$

ترکیب مشابه قبل است پس  
شکل





$$gini(لوهایی) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

$$gini(تکذاس) = 1 - \left(\frac{0}{3}\right)^2 - \left(\frac{3}{3}\right)^2 = 0$$


$$gini(کالینریا) = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{3}{8}$$

$$gini = \frac{4}{9} \times \frac{3}{10} + \frac{3}{8} \times \frac{4}{10} = \frac{17}{60} = 0.28\bar{3}$$



پس محل زندگی بهترین تقسیم لول است. حال برای تقسیم دوم هر کدام:



گلداس نصف قبل ۵ شد پس مرتب می‌کنیم انتخاب کنیم (یا اولاً صیغاً خبریم و  
۲ اعلام می‌کنیم.




$$= 1 - (1/3)^2 - (2/3)^2 = 4/9$$







ب) حیدرهای تپلی برای برش لعل به binary بودن جز محل زندگی که ملاک است که را بررسی میکنیم. چون تنها به سوراخ محل دایم تنها ترکیب تشریطی منطقی بودن یا نبودن هر مکان است. (مکان است یا نه) و حالات تپله (مثلا کالیزین یا لوله‌پوست یا نه) به همان حالات ساده که چه مسئله.



$$\begin{aligned} gini(سوراخ) &= 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{3}{8} \\ gini(کالیزین) &= 1 - \left(\frac{4}{6}\right)^2 - \left(\frac{2}{6}\right)^2 = \frac{4}{9} \end{aligned} \left\{ \begin{aligned} &\frac{3}{8} \times \frac{4}{10} + \frac{4}{9} \times \frac{6}{10} \\ &= \frac{5}{12} = 0.417 \end{aligned} \right.$$



$$gini = \frac{20}{49} \times \frac{7}{10} = \frac{2}{7} \approx 0.286 = \frac{20}{49}$$



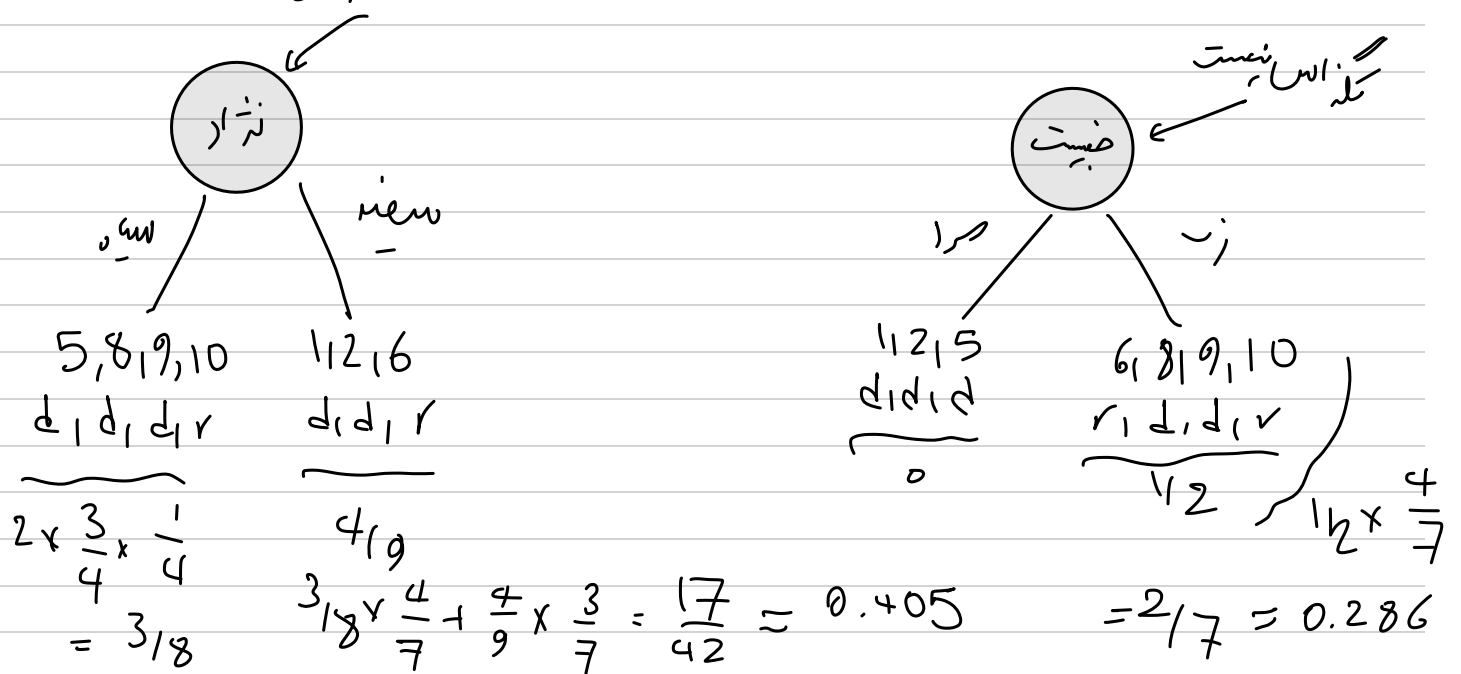
$$gini = \frac{4}{9} \times \frac{3}{10} + \frac{24}{49} \times \frac{7}{10} = \frac{10}{21} \approx 0.476$$

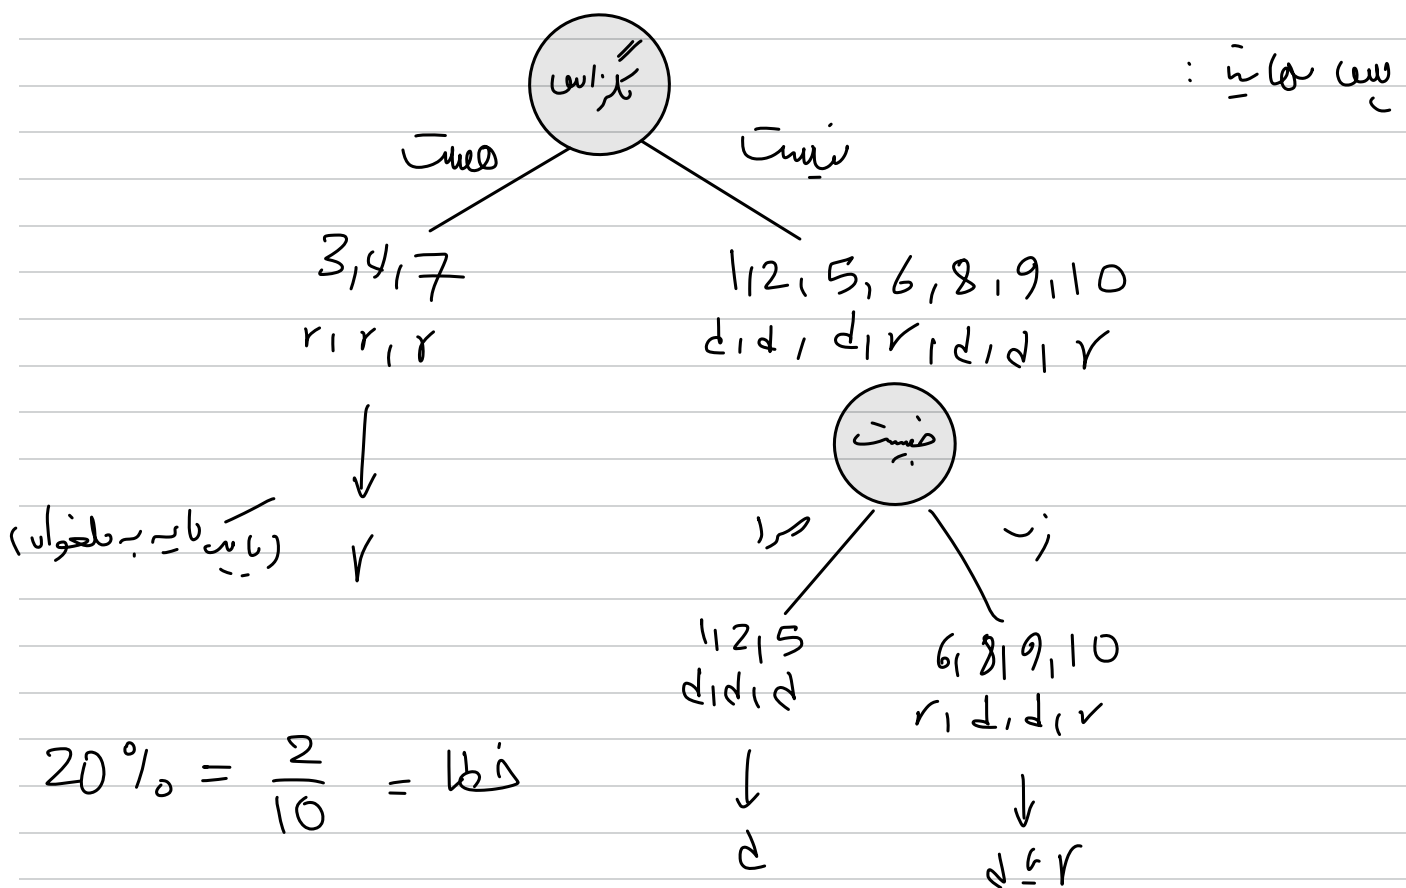

بسیار تصمیم لول نگه‌اس هست یا نه است. (دو تا این نه‌ار و نیست را بخش‌بیل  
 بدیم و جینی 0.48 داشته) برای تصمیم دیم بخش نگه‌اس هست :

ست نگه‌اس هست را با حل زندگی بگیریم 1 چون نگه‌اس هست

و بگیر اضافه کردن مثلاً کالفر نیه هست هم وابسته است محدود از این بهر

اصلاً نگه‌اس هست هم 2 هست : برای نیست





ج، به نظر می آید که این خطای بیش از حد است و از روی خوش بینی

استراتژی binary است. در صورتی که استراتژی multinary به عنوان

یافته و یعنی در صورتی که خطای کمتر دارد. به خوبی برای multinary

تقسیم طبیعی. بعضی مباحث حل زندگی در این مورد به طور طبیعی

چند حالت هست در multiclass نوعی تقسیم طبیعی و مستهودی تر است.

- اما در بحث ها عمق کمی خواهند داشت چون قدرت multiclass بیشتر است.

محابب multiclass :

- ریسک over fit شدن در آن بیشتر است چون پیچیدگی مدل بیشتر است.

است.

- پیاده سازی سخت تری دارد هم در پیاده سازی و هم در اجرا چون هیچ

کرنش به شرط هم ساده که هم از نظر سخت افزاری سریع تر است.

مختارای binary :

- درک آسان تر مدل ساده تری که کار کند بهتر است. اگر binary کار کند خوب

مدل ساده تر استفاده کنیم.

- در مدل های multiclass را هم شامل میشود. اگر داده هم در عمق  $\log C$

که  $C$  تعداد طبقه بندی ها است همان کار multiclass را کند. اما

عیب این که عمق زیاد شده و به مزیت این که هر شایه نژاد در مدل قبل پیچیده

باشند و نتوانند مثل بگراس نیست مدل ابتدای آن بود.

- میتوان اگر به صورت عدد باییم encode کرد که بهر دازش می

فوباست.

- این overfit است چون اگرچه  $\chi^2$  کمی دارد و ساده است.

مطلب هم در من برای قبی گفتن است برن تقسیم می طلبی را از

است به ، شودی نباشه یا محو که از زی دشونه.

4 - الوریتم جنگل تصادفی که آسانها از درخت هادست جمله و با این

دارواریا نش را کاهش دهد. و با یک دسته از درخت ها واریا نش کمی

نسبت به آموزش یک تک درخت دارند. چه که برای مثال اگر یک کمیت را می بین

$$\text{گیریم: } \text{Var}\left(\frac{\sum x_i}{N}\right) = \frac{1}{N^2} \text{Var}(\sum x_i) = \frac{1}{N} \text{Var}(x_1)$$

و در حالت کلی و پیچیده تر هم این به طور تقریبی به کار است.

در کنار این درخت های مختلف که هم روی فیچر هایی که می بیند تصادفی شده اند

و هم روی هست های از داده که می بیند امکان کمی دارد درخت نهایی روی

نوع یاد داده شود و فیت به نمونه نمی شود. حصار زیادی از یاد بوی

واریانس درخت کم فیت شدن به نوع است که هم با bagging

رنگه رانش بهترین بین چند درخت و هم می آید گین کمی و هم تصادفی

سازی این کاهش می آید. و این احتمال overfit هم کم شود.

3. 1- نشان مهم برای هر  $i$  و ساری برای جمله‌های سمت چپ درست است.

$$\mathbb{I}(\hat{y}_i \neq y_i) = \begin{cases} 0 & \hat{y}_i = y_i \quad (\text{sign}(H_t(x_i)) = y_i) \\ 1 & \hat{y}_i \neq y_i \quad (\text{sign}(H_t(x_i)) \neq y_i) \end{cases}$$

$$e^{-y_i H_t(x_i)} = \begin{cases} e^{-|H_t(x_i)|} & \hat{y}_i = y_i \\ e^{+|H_t(x_i)|} & \hat{y}_i \neq y_i \end{cases}$$

$$\begin{cases} > 0 \\ > 1 \end{cases}$$

$$e^{-y_i H_t(x_i)} > \mathbb{I}(\hat{y}_i \neq y_i) : \text{ساده در صورت}$$

$$\Rightarrow \frac{1}{N} \sum_i \exp(-y_i H_t(x_i)) \geq \frac{1}{N} \sum_i \mathbb{I}(\hat{y}_i \neq y_i)$$

2- هرگاه از  $D_i$  ها توسط عمل غایی استفاده می‌شود (بسته به درست یا غلط بودن

پیش‌بینی نیز یا کوچک می‌شود) (بافتن عمل  $y_i$  خود را انجام می‌دهد) :

و نتایج  $Z$  را می‌دهد :

$$D_{t+1}(i) = \frac{D_t(i) e^{-\alpha_t y_i h_t(x_i)}}{\sum_i D_t(i) e^{-\alpha_t y_i h_t(x_i)}} = Z_t^{-1} D_t(i) e^{-\alpha_t y_i h_t(x_i)}$$

$$H_t(x_i) = \sum_{t=1}^T \alpha_t h_t(x_i) \quad - 3$$

با جایگذاری این عبارت در  $E$  و جایگزینی ثوابت با جمع:

$$E = \frac{1}{N} \sum_{i=1}^N \exp(-\gamma_i H_t(x_i)) = \sum_{i=1}^N \frac{1}{N} \exp\left[\sum_{t=1}^T -\alpha_t \gamma_i h_t(x_i)\right]$$

فرد - در جمع  
فرد - در جمع

$$\prod_{t=1}^T z_t = \prod_{t=1}^{T-1} z_t \times \sum_{i=1}^N D_T(i) e^{-\alpha_T \gamma_i h_T(x_i)} \quad - 4$$

حال  $D_T(i)$  را از چیزی که در 2 بدست آمد جایگذاری می‌کنیم:

$$D_T(i) = Z_{T-1}^{-1} D_{T-1}(i) e^{-\alpha_{T-1} \gamma_i h_{T-1}(x_i)}$$

$$\Rightarrow \prod_{t=1}^T z_t = \prod_{t=1}^{T-1} z_t \cdot \sum_{i=1}^N Z_{T-1}^{-1} D_{T-1}(i) e^{-\sum_{t=T-1}^T \alpha_t \gamma_i h_t(x_i)}$$

با عبارت آخر خط می‌خورم

$$= \prod_{t=1}^{T-2} z_t \cdot \sum_{i=1}^N D_{T-1}(i) e^{-\sum_{t=T-1}^T \alpha_t \gamma_i h_t(x_i)}$$

حال دوباره  $D_{T-1}(i)$  را به حسب قبلی می‌نویسیم:

$$D_{T-1}(x_i) = Z_{T-2}^{-1} D_{T-2}(x_i) e^{-\alpha_{T-2} \gamma_i h_{T-2}(x_i)}$$

پس با استفاده از تکنیک هین ظهور عقب رفت  $T$

$$\prod_{t=1}^T Z_t = \sum_{i=1}^N D_{t(i)} \exp \left( \sum_{t=1}^T -\alpha_t \gamma_i h_t(x_i) \right)$$

$\swarrow$   
 $1/N$

اما در ابتدا داده ها یکسان وزن داده شده اند و  $D_{t(i)} = \frac{1}{N}$  پس :

$$\prod_{t=1}^T Z_t = \sum_{i=1}^N \frac{1}{N} \exp \left( \sum_{t=1}^T -\alpha_t \gamma_i h_t(x_i) \right) = E$$

که همان عبارت بخش 3 است.

5- توزیع وزن مرحله  $t$  + حتماً نرمالیزه است پس :

$$\begin{aligned} 1 - \epsilon_t &= \left[ \sum_i D_{t(i)} \right] - \left[ \sum_i D_{t(i)} \mathbb{I}(h_t(x_i) \neq \gamma_i) \right] \\ &= \sum_i D_{t(i)} [1 - \mathbb{I}(h_t(x_i) \neq \gamma_i)] \\ &= \sum_i D_{t(i)} \mathbb{I}(h_t(x_i) = \gamma_i) \end{aligned}$$

$$\Rightarrow (1 - \epsilon_t) e^{-\alpha_t} + \epsilon_t e^{\alpha_t}$$

$$= \sum_i D_{t(i)} \mathbb{I}(h_t(x_i) = \gamma_i) e^{-\alpha_t} + \sum_i D_{t(i)} \mathbb{I}(h_t(x_i) \neq \gamma_i) e^{+\alpha_t}$$



$$= \sum_i D_{+}(i) \left[ \underbrace{\mathbb{I}(h_{+}(x_i) = \gamma_i) e^{-\alpha_{+}} + \mathbb{I}(h_{+}(x_i) \neq \gamma_i) e^{+\alpha_{+}}}_{= e^{-\alpha_{+} \gamma_i h_{+}}} \right]$$

چون کلام از دسته‌بندی‌های صنف  $+1$  و  $-1$  - فروجه‌ی بهر و فـدـ آن در  $\gamma_i$  در صورت درست بودن  $+1$  و در صورت نادرست بودن  $-1$  است.

$$\Rightarrow (1 - \epsilon_{+}) e^{-\alpha_{+}} + \epsilon_{+} e^{+\alpha_{+}} = \sum_i D_{+}(i) e^{-\alpha_{+} \gamma_i h_{+}} = Z_{+}$$

$$Z_{+} = (1 - \epsilon_{+}) e^{-\alpha_{+}} + \epsilon_{+} e^{+\alpha_{+}} \quad \text{6- درخت قبل بیدیم}$$

در حد  $\alpha_{+} \rightarrow \pm \infty$  ،  $Z_{+} \rightarrow +\infty$  چون هر بار یک از  $\gamma_i$  ها از بین می‌رود

و باریک به  $+\infty$  می‌رود و  $\epsilon_{+}$  و  $1 - \epsilon_{+}$  صفت است پس کمینه

$Z_{+}$  "حدا" که از تمام موضوعی‌اش است :

$$\frac{\partial Z_{+}}{\partial \alpha_{+}} = - (1 - \epsilon_{+}) e^{-\alpha_{+}} + \epsilon_{+} e^{+\alpha_{+}} = 0$$

$$(1 - \epsilon_{+}) = \epsilon_{+} e^{2\alpha_{+}}$$

$$\Rightarrow \boxed{\alpha_{+} = \frac{1}{2} \ln \frac{1 - \epsilon_{+}}{\epsilon_{+}}} = \ln \sqrt{\frac{1 - \epsilon_{+}}{\epsilon_{+}}}$$

چون در سرها  $(\pm \infty)$  تابع به  $+\infty$  رفته تنها نقطه‌ی موهن آن صفا همان کمینه‌ی گلوبال است. (چون نرم و پیوسته و — — — — هم هست)