


1.

$$x_1 = (-1, -1)$$

$$x_2 = (0, 0)$$

$$x_3 = (1, 1)$$



(1)

پاسخ به صورت متلودی واقع است اما به همان باروشش که حساب میکنیم:

$$(||v|| = 1)$$

$$\sigma^2 = \sum (v^T x_i)^2 = (x^T v)^2 = v^T x x^T v, \quad v^T v = 1$$

$$\nabla \mathcal{L} = \nabla_v (\sigma^2 - \lambda v^T v) = 2(x x^T - \lambda I)v = 0$$

$$\Rightarrow |x x^T - \lambda I| = 0$$

$$X^T = \begin{bmatrix} -x_1 & -x_2 & -x_3 \\ -x_1 & -x_2 & -x_3 \end{bmatrix} = \begin{bmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}$$

$$X X^T = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

$$\begin{vmatrix} 2-\lambda & 2 \\ 2 & 2-\lambda \end{vmatrix} = (2-\lambda)^2 - 2^2 = 0 \Rightarrow 2-\lambda = \pm 2$$

$$\lambda = 2 \pm 2$$

$$= 4, 0$$

اما $\text{rank}(XX^T) = 1$ و تنها یک مولفه PCA داریم. ($\lambda = 4$) به صورت
 شعاعی هم داده ها با یک محور قابل توصیف هستند.

$$\lambda = 4 \Rightarrow \begin{bmatrix} -2 & 2 \\ 2 & -2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow x = y$$

$$x^2 + y^2 = 1 \Rightarrow v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{و} \quad v_1 = \frac{-1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

طبق تعریف دروس تنها می‌توانیم داده‌های با ویژگی مشترک را به صورت مولفه اصلی (لازم) هستند و
 نمایش هم رتبه ماتریس XX^T است. اما به هر حال می‌توان آن مولفه
 را هم که برای توصیف داتاست لازم نیست موارد را پس حذف کرد به علاوه:

$$\lambda = 0 \Rightarrow \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow x = -y$$

$$x^2 + y^2 = 1 \Rightarrow v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad \text{و} \quad v_2 = \frac{-1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$x'_1 = \begin{bmatrix} v_1^T x_1 \\ v_2^T x_1 \end{bmatrix} = \begin{bmatrix} -\sqrt{2} \\ 0 \end{bmatrix} \quad (2)$$

$$x'_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x'_3 = \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix}$$

$$\sigma_1^2 = x_{11}'^2 + x_{21}'^2 + x_{31}'^2 = \sqrt{2}^2 + 0^2 + \sqrt{2}^2 = 4$$

$$v_1^T x x^T v_1 = \underbrace{\lambda v_1^T x x^T v_1}_{\lambda v_1^T v_1} = \lambda \quad \text{چون } \lambda = 4$$

$$\sigma_2^2 = x_{12}'^2 + x_{22}'^2 + x_{32}'^2 = 0 + 0 + 0 = 0 \quad (\lambda_2 = 0)$$

$$\sigma_1^2/n = 4/3, \quad \sigma_2^2/n = 0 \quad \text{واریانس های نرمال شده:}$$

(3) خطای بازسازی می باشد چون هر سه بردار روی خط مراد دارد. ~ صبر است

مستقیم:

$$E_i = \|x_i - (x_i \cdot e_1) e_1\|^2 =$$

$$\| (-1, -1) - (-1, -1) \cdot \frac{1}{\sqrt{2}} (1, 1) \cdot \frac{1}{\sqrt{2}} (1, 1) \|^2$$

$$= \| (-1, -1) - \frac{1}{2} (-2, -2) \|^2 = 0 \quad \checkmark$$

$$E_2 = \| x_2 - (x_2 \cdot e_1) e_1 \|^2 = \| (0, 0) - (0, 0) \cdot \frac{(1, 1)}{\sqrt{2}} \frac{(1, 1)}{\sqrt{2}} \|^2$$

$$= 0 \quad \checkmark$$

$$E_3 = \| x_3 - (x_3 \cdot e_1) e_1 \|^2 = \| (1, 1) - (1, 1) \cdot \frac{(1, 1)}{\sqrt{2}} \frac{(1, 1)}{\sqrt{2}} \|^2 = 0 \quad \checkmark$$

2.

(1)

$$A: P(A)$$

A به چیزی بستگی ندارد :

$$F: P(F)$$

$$S: P(S|F, A)$$

$$H: P(H|S)$$

$$N: P(N|S)$$

هر فاکتورالیزاسیون Expected Maximization (EM) باید تحت لایه A با صحت
مشاهده منطبق نیست پس باید مقادیر را در این مواقع تخمین بزنیم .

$$P(A=1 | F, S, H, N) = \frac{P(A=1, F, S, H, N)}{P(F, S, H, N)}$$

(2)

$$P(A=1 | F, S, H, N) = P(A=1) \cdot P(F) \cdot P(S|F, A=1) \cdot P(H|S) \cdot P(N|S)$$

$$P(F, S, H, N) = P(F) \cdot P(H|S) \cdot P(N|S) \times$$

$$[P(A=0) \cdot P(S|F, A=0) + P(A=1) \cdot P(S|F, A=1)]$$

$$\Rightarrow P(A=1 | F, S, H, N) =$$

$$P(A=1) \cdot P(F) \cdot P(S | F, A=1) \cdot P(H | S) \cdot P(N | S)$$

$$P(F) \cdot P(H | S) \cdot P(N | S) \times [P(A=0) \cdot P(S | F, A=0) + P(A=1) \cdot P(S | F, A=1)]$$

(3) باید طبق تعریف پتری سارکوف والدین، فرزندان و سایر والدین فرزندان

A را لحاظ کنیم که متغیرهای F و S هستند.

(4) عبارات های فیلتر یعنی $P(H | S)$ و $P(N | S)$ از صورت و خروج ساده

هستند. $P(F)$ هم هست اما نیازی نیست.

$$P(A=1 | F, S, H, N) =$$

$$P(A=1) \cdot P(F) \cdot P(S | F, A=1)$$

$$P(F) \cdot [P(A=0) \cdot P(S | F, A=0) + P(A=1) \cdot P(S | F, A=1)]$$

(5) برای قضاوتی که آن را غایبی می‌نامند همان $1 = 0$ و $0 = 1$ را به طریقه

متناظر به تدریس اما چون سوال از $1 =$ استفاده کرد. این بار رابطه ها وابسته

هستند:

$$P(A=1)$$

$$P(S=1, F=0, A=0)$$

$$P(S=1, F=0, A=1) \quad (\text{فهردهای منطقی ممکن } A, F)$$

$$P(S=1, F=1, A=0)$$

$$P(S=1, F=1, A=1)$$

6) جای مقایسه غیر قابل مشاهده ("؟) مقدار احتمال محاسبه شد را به عنوان تخمین فراوانی و آنرا 5 مقدار مشاهده شد داریم:

$$P(A=1) = \frac{1}{5} (1+1+0+0.8+0.4) = 0.64$$

$$P(S=1|F=0, A=1) = \frac{P(S=1, F=0, A=1)}{P(F=0, A=1)}$$

$$= \frac{\cancel{1/5} (1+0+0+0.8 \times 0 + 0.4 \times 1)}{\cancel{1/5} (1+1+0+0.8+0.4)} = 0.4375$$


1) به نتیجه‌ی درستی نخواهیم رسید و نمی‌توانیم به درستی دسته‌بندی کنیم.

کنیم چه اگر دسته‌بندی k -means نمی‌تواند اشکال هندسی غیر محذب را دسته‌بندی کند. به آن دسته‌ها به اساس فاصله‌ی اقلیدسی از تعدادی نقاط تعیین می‌شوند. شکل حاصل حتی این شکل محذب خواهد بود و لذا اشکال غیر محذب را شکل در تصویر قابل تفکیک نیستند.


2) نرمان سازی شکل الگوریتم در این حالت خاص را حل نمی‌کند. اما به کمک آن می‌توانیم دانه‌ها باعث می‌شود الگوریتم k -means با صحتی ایجاد داده‌ها به یک اخصیت برخورد کند. به آن الگوریتم در فضا نقاط و دایره / اگر نه، های تکرار می‌دهد. پس می‌تواند بین ایجاد مختلف دایره / آن‌ها تمیز قائل شود. این گونه صحتی که ذاتاً در آن تغییر کم است کم اخصیت که از صحتی خواهد بود که در آن تغییرات بزرگ است. رفرنس خطاها و نویزهای ایجاد با اعداد بزرگ هم $high$ می‌شود.

مثال: فرض کنید بخواهیم چنان با هم از نظر اخصیت دسته‌بندی تفاوتی نداشته، اما یک جور را به سادگی می‌توانیم و دیگری را با صحت اندازگی نمی‌توانیم و به خود

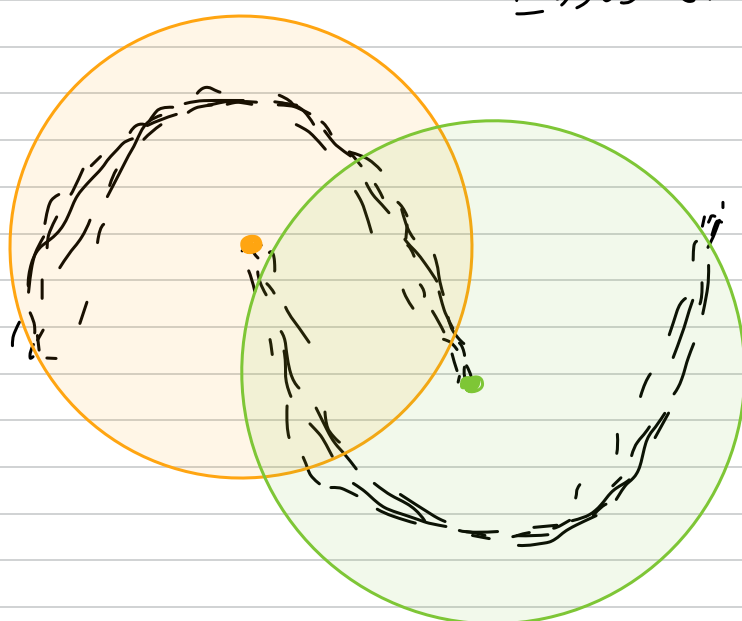
الگوریتم بهم . یا فرض کنه نوسانات یا قیمت بدجین را در یک جو
 بر ریال بهم د جین بگیم را در جو بگیم به دلار (که بعینه به همکار است به اساس
 هر دو این ها بگویند بهم بعینه بکنند) حال آن جوی در ریال بود و
 بدشال ببل آن جوی که به ساتی می بود حینی اصیت بیشتری به خواهه
 که در به تنهایی ششاع رایبه هلاصین خواهه کرد.



تفاوت در جو x (یعنی) حد معین شود . اما با اعمال نرمال سازی حال واحد لیه
 قیمت خوبی به این ها خواهد بود که اگر $\sigma_x^2 = \sigma_y^2 = 1$ (پس از نرمال
 کردن) و ما بعین شلال فوهندراشت :



۳) احتمال الگوریتم به چینی تپهای فلوید میسر:



عموم امکان تقلیل

اثبات ریاضی: فرضی خلف کنج k -means توانسته باشد شکل ست چپ


بالا را به درستی تقلیل کند. در آن صورت شکل عماد داخل دایره ای به مرکز

به دست آمده است پس دایره ای به این صورت وجود دارد:



هر نقطه ای که داخل دایره به هم وصل شوند

نیز داخل دایره هستند پس



این فضای داخلی شکل \wedge که داریم یک داخل دایره سی خود \wedge است

مهرای \wedge هم همینطور. برای همین k -means می تواند مهری که داخل

این هاست را به صورت هم زمان درست تشخیص داده باشد.

لایه ی k -means با تفکیک اشکال غیر محدب مشکل دارد.